

Module 02 — Statistiques descriptives essentielles

Bootcamp Data Analyst — From Zero to Hero | Niveau Débutant · Acte I

Ce que tu seras capable de faire à la fin de ce module

- Identifier le type d'une variable et choisir les bons outils en conséquence
- Calculer et interpréter la moyenne, la médiane, le mode et l'étendue
- Comprendre ce que mesurent la variance et l'écart-type
- Lire les percentiles et quartiles, détecter les outliers avec l'IQR
- Lire une distribution et repérer des anomalies à l'œil nu
- Analyser la relation entre deux variables (corrélation, covariance, contingence)
- Choisir le bon indicateur selon la situation

 **Durée estimée** : 45 minutes

 **Prérequis** : Module 01 complété. Aucune formule mathématique complexe — on reste dans le concret.

1. Pourquoi les statistiques ?

Imagine que tu travailles dans une entreprise de 500 employés. Ton manager te demande :

"Comment se portent nos salaires cette année ?"

Tu ne vas pas lui lire 500 lignes de chiffres. Tu vas lui donner **un résumé intelligent** :

- *"Le salaire moyen est de 450 000 FCFA."*
- *"Mais la moitié des employés gagne moins de 300 000 FCFA."*
- *"Et l'écart entre le plus bas et le plus haut est énorme : 120 000 vs 4 500 000."*

C'est exactement ça, les statistiques descriptives : des outils pour résumer, comparer et communiquer des données en quelques chiffres clés.

💡 *Un Data Analyst sans stats descriptives, c'est comme un médecin sans thermomètre. C'est son premier outil de diagnostic.*

2. Population vs Échantillon — une distinction fondamentale

Avant tout calcul, une question s'impose : **sur quoi travaille-t-on exactement ?**

Définitions

Population = l'ensemble **complet** des individus ou données qu'on souhaite étudier

Échantillon = un **sous-ensemble** de la population, sélectionné pour l'analyse

	POPULATION	ÉCHANTILLON
Définition	Tous les éléments concernés	Un sous-ensemble représentatif
Exemple télécom	Tous les 8 millions d'abonnés d'un opérateur	5 000 abonnés sélectionnés pour une enquête
Exemple RH	Tous les 500 employés d'une entreprise	Les 10 employés de notre dataset fil rouge
Exemple e-commerce	Toutes les transactions de l'année	Les transactions du mois de mars

Pourquoi cette distinction compte en pratique

En théorie, on voudrait toujours travailler sur la population entière. En pratique :

- C'est **trop coûteux** (sonder 8 millions d'abonnés)
- C'est **trop long** (analyser 10 ans de transactions)
- C'est parfois **impossible** (on ne peut pas tester tous les smartphones qui sortiront de l'usine)

Donc **presque toujours, un DA travaille sur un échantillon** — et il doit garder ça en tête quand il interprète ses résultats.

Impact sur les calculs — le fameux $n-1$

La distinction population/échantillon change les formules. L'exemple le plus concret : l'**écart-type**.

Écart-type population → on divise par n
 Écart-type échantillon → on divise par $n-1$

Pourquoi $n-1$? Parce qu'un échantillon **sous-estime légèrement** la dispersion réelle de la population. Diviser par $n-1$ corrige ce biais — c'est ce qu'on appelle la **correction de Bessel**.

💡 Quand tu utiliseras Python (Acte IV), tu verras `std()` retourner un résultat avec `ddof=1` par défaut — c'est exactement ça. Ce n'est pas un bug, c'est la formule correcte pour un échantillon.

Statistiques descriptives vs inférentielles

Cette distinction ouvre sur deux grandes branches des statistiques :

	STATISTIQUES DESCRIPTIVES	STATISTIQUES INFÉRENTIELLES
Objectif	Décrire et résumer les données qu'on a	Généraliser à la population entière
Question type	"Quel est le salaire médian de nos 10 employés ?"	"Peut-on conclure que tous les employés du secteur gagnent autant ?"
Outils	Moyenne, médiane, écart-type, graphiques	Tests d'hypothèses, intervalles de confiance, p-values
Ce module	✅ On est ici	❌ Niveau avancé (Acte X)

📌 Dans ce module, on fait uniquement des **statistiques descriptives** — on décrit ce qu'on observe dans notre dataset, sans chercher à généraliser. Les stats inférentielles arrivent en Acte X avec R.

3. Les types de variables — premier réflexe du DA

Avant de calculer quoi que ce soit, un DA doit répondre à une question fondamentale :

"De quel type est ma variable ?"

Parce que le type de variable **détermine directement les outils à utiliser**. Calculer une moyenne sur des codes postaux ou une corrélation sur des niveaux de satisfaction — c'est une erreur classique de débutant.

Variables quantitatives — des nombres qui ont un sens numérique

Quantitative continue — peut prendre une infinité de valeurs dans un intervalle

- Exemples : revenu (450 230,75 FCFA), température (27,3°C), taille (1,73m)
- Outils : moyenne, médiane, écart-type, histogramme

Quantitative discrète — valeurs entières, comptables

- Exemples : nombre de transactions (3), nombre d'enfants (2), nombre de pannes (7)
 - Outils : moyenne, médiane, mode, diagramme en barres
-

Variables qualitatives — des catégories, pas des chiffres

Qualitative nominale — catégories sans ordre logique

- Exemples : région (Abidjan, Bouaké, San Pedro), type de forfait (500, internet, voix), couleur
- Outils : mode, tableau de contingence, diagramme circulaire
- ⚠ *Calculer une moyenne sur des régions n'a aucun sens*

Qualitative ordinale — catégories avec un ordre logique

- Exemples : satisfaction (Faible / Moyen / Élevé), niveau d'études (Bac / Licence / Master)
 - Outils : médiane, mode, corrélation de Spearman
 - ⚠ *On peut ordonner, mais la distance entre les catégories n'est pas mesurable*
-

Tableau de synthèse

TYPE	EXEMPLE	MOYENNE	MÉDIANE	MODE	CORRÉLATION
Quantitative continue	Salaire	✓	✓	✓	Pearson
Quantitative discrète	Nb transactions	✓	✓	✓	Pearson
Qualitative ordinale	Satisfaction	✗	✓	✓	Spearman
Qualitative nominale	Région	✗	✗	✓	Contingence

💡 Dans ce module, notre dataset salaires est une variable **quantitative continue**. On peut donc utiliser tous les indicateurs sans restriction.

4. Le dataset fil rouge

Pour tout ce module, on va travailler avec le même petit dataset : **les salaires mensuels de 10 employés d'une PME** (en milliers de FCFA).

EMPLOYÉ	SALAIRE (K FCFA)
Adjoua	280
Brice	310
Camille	310
Drissa	350
Estelle	400
Fanta	420
Gilles	480
Hervé	520
Inès	600
Jean-Marc	4 500

⚠ Tu remarques quelque chose ? Jean-Marc gagne **10x plus** que la plupart de ses collègues. Ce genre de valeur extrême — on appelle ça un **outlier** — va complètement changer certains calculs. On va voir comment.

Données triées dans l'ordre croissant :

280 · 310 · 310 · 350 · 400 · 420 · 480 · 520 · 600 · 4500

5. La moyenne

Définition

La **moyenne** (ou moyenne arithmétique), c'est la somme de toutes les valeurs divisée par le nombre de valeurs.

$$\text{Moyenne} = (\text{somme de toutes les valeurs}) \div (\text{nombre de valeurs})$$

Calcul sur notre dataset

$$\begin{aligned}\text{Somme} &= 280 + 310 + 310 + 350 + 400 + 420 + 480 + 520 + 600 + 4500 \\ &= 8\,170 \text{ k FCFA}\end{aligned}$$

$$\text{Moyenne} = 8\,170 \div 10 = 817 \text{ k FCFA}$$

Le problème

La moyenne est de **817 000 FCFA**. Pourtant, **9 employés sur 10 gagnent moins de 620 000 FCFA**.

La moyenne a été **tirée vers le haut** par le salaire exceptionnel de Jean-Marc.

Si tu dis à tes collègues "*le salaire moyen ici c'est 817k*", tu leur donnes une image faussée de la réalité.

⚠ **La moyenne est sensible aux outliers.** Dès qu'il y a des valeurs extrêmes dans tes données, la moyenne seule devient trompeuse. C'est pourquoi on la complète toujours avec la médiane.

6. La médiane

Définition

La **médiane**, c'est la valeur qui se trouve **exactement au milieu** quand on trie les données dans l'ordre croissant. Elle coupe le dataset en deux moitiés égales : 50% des valeurs en dessous, 50% au-dessus.

Calcul sur notre dataset

Notre dataset trié :

```
280 · 310 · 310 · 350 · [400 · 420] · 480 · 520 · 600 · 4500
                        ↑       ↑
                    5e valeur 6e valeur
```

On a 10 valeurs (nombre pair) → la médiane est la **moyenne des 2 valeurs du milieu** :

```
Médiane = (400 + 420) ÷ 2 = 410 k FCFA
```

La différence avec la moyenne

INDICATEUR	VALEUR	INTERPRÉTATION
Moyenne	817 k FCFA	Faussée par Jean-Marc
Médiane	410 k FCFA	Représente mieux la réalité des 10 employés

💡 **Règle pratique** : Pour les salaires, les prix immobiliers, les revenus — toujours préférer la médiane. Elle résiste aux outliers. La moyenne est utile quand les données sont bien réparties sans valeurs extrêmes.

Exemple concret : Quand l'INSEE publie le "salaire médian" en France (environ 2 000 €/mois en 2024), il utilise la médiane — pas la moyenne — précisément pour éviter que les très hauts salaires faussent l'image.

7. Le mode

Définition

Le **mode**, c'est la valeur qui apparaît **le plus souvent** dans le dataset.

Calcul sur notre dataset

```
280 · 310 · 310 · 350 · 400 · 420 · 480 · 520 · 600 · 4500
      ↑      ↑
    apparaît 2 fois
```

Mode = 310 k FCFA — c'est la seule valeur qui se répète.

Quand utiliser le mode ?

Le mode est particulièrement utile pour les **données catégorielles** (non numériques) :

SITUATION	QUESTION	MODE UTILE
E-commerce	Quelle taille de vêtement se vend le plus ?	Taille M
Télécom	Quelle recharge est la plus achetée ?	500 FCFA
RH	Quel département concentre le plus d'effectifs ?	Commercial
Transport	Quel trajet est le plus emprunté ?	Cocody → Plateau

💡 *Un dataset peut avoir plusieurs modes (bimodal, multimodal) ou aucun si toutes les valeurs sont différentes.*

8. L'étendue

Définition

L'**étendue** (ou range), c'est la différence entre la valeur **maximale** et la valeur **minimale**. Elle mesure l'amplitude totale des données.

Calcul sur notre dataset

```
Étendue = Maximum - Minimum  
         = 4 500 - 280  
         = 4 220 k FCFA
```

Ce que ça dit

Une étendue de **4 220 000 FCFA** entre le salaire le plus bas et le plus haut dans cette entreprise — c'est un signal immédiat d'**inégalité salariale forte**.

⚠ **Limite de l'étendue** : elle ne dépend que de 2 valeurs (le min et le max) et ignore toute la distribution entre les deux. Un seul outlier suffit à exploser l'étendue. C'est pour ça qu'on complète avec l'écart-type.

9. La variance et l'écart-type

L'idée intuitive

Imagine deux classes de 5 élèves avec les notes suivantes :

Classe A : 10 · 10 · 10 · 10 · 10 → Moyenne = 10

Classe B : 2 · 5 · 10 · 15 · 18 → Moyenne = 10

Les deux classes ont la **même moyenne**. Pourtant elles ne se ressemblent pas du tout.

- Classe A : tout le monde a exactement 10 → **aucune dispersion**
- Classe B : les notes varient de 2 à 18 → **forte dispersion**

La **variance** et l'**écart-type** mesurent exactement cette dispersion — à quel point les valeurs s'éloignent de la moyenne.

Définitions

Variance = moyenne des carrés des écarts à la moyenne

Pour chaque valeur :

1. Calcule l'écart à la moyenne : (valeur - moyenne)
2. Mets cet écart au carré : (valeur - moyenne)²
3. Fais la moyenne de tous ces carrés

Écart-type = racine carrée de la variance

$$\text{Écart-type} = \sqrt{\text{Variance}}$$

💡 On utilise l'écart-type plutôt que la variance car il est exprimé dans la **même unité** que les données originales. La variance des salaires serait en "FCFA²" — ce qui ne veut rien dire. L'écart-type, lui, est en FCFA.

Comment lire l'écart-type

ÉCART-TYPE	CE QUE ÇA SIGNIFIE
Faible	Les valeurs sont regroupées proches de la moyenne — données homogènes
Élevé	Les valeurs sont très dispersées — forte variabilité

Exemples concrets :

- Une chaîne de fast-food contrôle ses temps de préparation. Écart-type faible = bonne cohérence opérationnelle ✅
- Un opérateur télécom analyse la qualité réseau par antenne. Écart-type élevé = certaines zones beaucoup moins bien couvertes ⚠️
- Un DA analyse les revenus clients. Écart-type très élevé = base clients très hétérogène → segmentation nécessaire


10. La distribution

Définition

La **distribution** décrit comment les valeurs se répartissent dans un dataset. Elle répond à la question : *"Est-ce que les valeurs sont concentrées quelque part, ou dispersées partout ?"*

La distribution normale (courbe en cloche)

C'est la distribution la plus connue. Elle ressemble à une cloche symétrique :



Dans une distribution normale :


- **68%** des valeurs sont à moins d'1 écart-type de la moyenne
- **95%** des valeurs sont à moins de 2 écarts-types
- **99,7%** des valeurs sont à moins de 3 écarts-types

Exemples réels : tailles humaines, erreurs de mesure, QI, températures journalières.

Les distributions asymétriques


Dans la vraie vie, les données ne sont pas toujours symétriques.

Asymétrie à droite (queue longue à droite) :



Exemples : **salaires** (notre dataset !), revenus, prix immobiliers, durée de vie des produits.

Asymétrie à gauche (queue longue à gauche) :



Moyenne < Médiane < Mode

Exemples : âge de départ à la retraite, notes à un examen facile.

Pourquoi c'est important pour un DA ?

Connaître la forme de ta distribution te dit **quelle mesure utiliser** :

DISTRIBUTION	INDICATEUR RECOMMANDÉ
Symétrique (normale)	Moyenne + Écart-type
Asymétrique ou outliers	Médiane + Étendue interquartile
Catégorielle	Mode

11. Fréquences — compter et proportionner

Avant de parler de distribution en forme de cloche ou de courbe, on doit savoir **compter**. C'est là qu'entrent les fréquences.

Fréquence absolue — combien de fois ?

La **fréquence absolue** d'une valeur, c'est simplement le **nombre de fois qu'elle apparaît** dans le dataset.

Exemple — types de recharges vendues en une journée :

TYPE DE RECHARGE	FRÉQUENCE ABSOLUE
Recharge 500 FCFA	142
Recharge 1 000 FCFA	89
Forfait internet	203
Forfait voix	66
Total	500

Fréquence relative — quelle proportion ?

La **fréquence relative** divise la fréquence absolue par le total. Elle donne un **pourcentage** — beaucoup plus parlant pour un décideur.

Fréquence relative = Fréquence absolue ÷ Total

TYPE DE RECHARGE	FRÉQUENCE ABSOLUE	FRÉQUENCE RELATIVE
Recharge 500 FCFA	142	28,4%
Recharge 1 000 FCFA	89	17,8%
Forfait internet	203	40,6%
Forfait voix	66	13,2%
Total	500	100%

Insight immédiat : *"Le forfait internet représente 40% des ventes — c'est le produit star de la journée."*

💡 En pratique, tu diras rarement "142 ventes de recharge 500". Tu diras "28% des ventes". La fréquence relative est le langage du business.

Fréquence cumulée — jusqu'où ?

La **fréquence cumulée** additionne les fréquences au fur et à mesure. Elle répond à des questions comme "Quelle proportion de clients génère X% du chiffre d'affaires ?"

Exemple — montants de transactions triés par ordre croissant :

TRANCHE DE MONTANT	FRÉQ. RELATIVE	FRÉQ. CUMULÉE
0 – 500 FCFA	35%	35%
500 – 2 000 FCFA	40%	75%
2 000 – 5 000 FCFA	18%	93%
5 000 FCFA et +	7%	100%

Lecture : "75% des transactions sont inférieures à 2 000 FCFA. Seulement 7% dépassent 5 000 FCFA — mais ces gros clients méritent une attention particulière."

💡 La fréquence cumulée est la base de la **loi de Pareto** (règle 80/20) : dans beaucoup de datasets business, 20% des clients génèrent 80% du chiffre d'affaires. Tu le vérifieras avec un tableau de fréquences cumulées.

12. L'histogramme — visualiser une distribution

Définition

Un **histogramme** est un graphique en barres qui représente la **distribution d'une variable quantitative**. Chaque barre correspond à un intervalle de valeurs (appelé **classe**) et sa hauteur indique la fréquence de cet intervalle.


Histogramme vs Bar chart — la confusion classique

Ce sont deux graphiques qui se ressemblent visuellement mais qui sont **fondamentalement différents** :

	HISTOGRAMME	BAR CHART (DIAGRAMME EN BARRES)
Type de variable	Quantitative continue	Qualitative ou discrète
Axe X	Intervalles numériques continus	Catégories distinctes
Barres	Collées (pas d'espace)	Séparées
Question	"Comment se répartissent les valeurs ?"	"Combien y a-t-il dans chaque catégorie ?"
Exemple	Distribution des salaires	Ventes par type de forfait

Comment lire un histogramme

Exemple — distribution des salaires de notre dataset :



Ce que l'histogramme révèle immédiatement :

- La **majorité des salaires** se concentre entre 280 et 620 k FCFA
- Il y a une **barre isolée à droite** → Jean-Marc, l'outlier
- La distribution est **asymétrique à droite** — queue tirée par cet outlier

Ce que la forme de l'histogramme te dit

FORME OBSERVÉE	INTERPRÉTATION	ACTION DA
Cloche symétrique	Distribution normale	Moyenne + écart-type suffisent
Queue à droite	Outliers élevés (salaires, revenus)	Utiliser la médiane
Queue à gauche	Outliers bas (notes, âges)	Vérifier les valeurs minimales
Deux bosses (bimodal)	Deux groupes distincts dans les données	Segmenter en 2 populations
Barre plate (uniforme)	Toutes les valeurs sont équiprobables	Pas de tendance centrale claire

💡 En Python (Acte IV), tu généreras des histogrammes en une ligne de code avec `plt.hist()` ou `df.hist()`. En R, c'est `hist()`. En Power BI, c'est un visuel natif. Maintenant tu sais ce que tu regardes.

13. Percentiles, quartiles et IQR — détecter les outliers

Les percentiles

Un **percentile** divise un dataset trié en 100 parties égales. Le percentile P indique que **P% des valeurs sont inférieures** à cette valeur.


Exemples concrets :

- "Tu es au 90e percentile de revenus" → 90% des gens gagnent moins que toi

- "La latence réseau au P95 est de 250ms" → 95% des requêtes répondent en moins de 250ms
- "Le score au P50" → c'est exactement la médiane

Les quartiles — les 3 percentiles clés

Les **quartiles** divisent le dataset en 4 parties égales. Ce sont les percentiles les plus utilisés :



QUARTILE	PERCENTILE	SIGNIFICATION
Q1	P25	25% des valeurs sont en dessous
Q2	P50	La médiane — 50% en dessous
Q3	P75	75% des valeurs sont en dessous

Calcul sur notre dataset salaires :

280 · 310 · 310 · 350 · 400 · 420 · 480 · 520 · 600 · 4500

Q1 = moyenne entre 310 et 350 = 330 k FCFA

Q2 = médiane = 410 k FCFA

Q3 = moyenne entre 480 et 520 = 500 k FCFA

L'IQR — Interquartile Range

L'**IQR** (écart interquartile) est la différence entre Q3 et Q1. Il mesure la dispersion des **50% centraux** du dataset — en ignorant les valeurs extrêmes.

```
IQR = Q3 - Q1  
      = 500 - 330  
      = 170 k FCFA
```

💡 L'IQR est la version robuste de l'étendue. Là où l'étendue dépend du min et du max (donc des outliers), l'IQR se concentre sur le cœur des données.

Détecter les outliers avec l'IQR — la règle de Tukey

C'est la méthode standard pour identifier automatiquement les outliers :

```
Borne inférieure = Q1 - 1.5 × IQR  
Borne supérieure = Q3 + 1.5 × IQR  
  
Toute valeur en dehors de ces bornes = outlier
```


Application sur notre dataset :

```
Borne inférieure = 330 - (1.5 × 170) = 330 - 255 = 75 k FCFA  
Borne supérieure = 500 + (1.5 × 170) = 500 + 255 = 755 k FCFA  
  
Jean-Marc : 4 500 k FCFA > 755 k FCFA → ✅ Confirmé outlier
```

Cette règle est utilisée automatiquement par Python (`describe()`), R (`boxplot()`), et Power BI pour détecter les anomalies.

Le box plot — visualiser tout ça en un coup d'œil

Le **box plot** (boîte à moustaches) résume visuellement les quartiles et les outliers :



- **La boîte** = les 50% centraux (de Q1 à Q3)
- **La ligne dans la boîte** = la médiane (Q2)
- **Les moustaches** = valeurs dans les bornes de Tukey
- **Les points isolés** = outliers

💡 Tu vas créer des box plots en Python (Acte IV) et Power BI (Acte VII). Maintenant tu sais ce qu'ils représentent.

14. Stats à 2 variables — Analyser les relations

Jusqu'ici on a analysé **une seule variable à la fois** (les salaires). Mais un DA travaille souvent sur des questions comme :

- "Est-ce que le budget marketing influence les ventes ?"
- "Les zones avec plus d'antennes ont-elles plus d'abonnés ?"
- "Quel type de client achète quel produit ?"

Ces questions impliquent **2 variables**. C'est ce qu'on appelle les **statistiques bivariées**.

9.1 Le nuage de points — voir la relation

La première chose à faire quand on analyse 2 variables numériques : les **visualiser ensemble**.

Exemple : budget marketing (en millions FCFA) vs ventes (en millions FCFA) sur 6 mois :



On voit clairement que **quand le budget augmente, les ventes augmentent aussi**. Les points forment une ligne montante. C'est ce qu'on appelle une **corrélation positive**.

9.2 La covariance — sens de la relation

La **covariance** mesure si deux variables évoluent dans le même sens ou en sens inverse.

Covariance > 0 → Les deux variables augmentent ensemble
Covariance < 0 → Quand l'une monte, l'autre descend
Covariance ≈ 0 → Pas de relation linéaire apparente

Exemples concrets :

VARIABLE 1	VARIABLE 2	COVARIANCE	INTERPRÉTATION
Budget marketing	Ventes	Positive	Plus on investit, plus on vend
Prix d'un produit	Quantité vendue	Négative	Plus c'est cher, moins on vend
Couleur des yeux	Salaire	≈ 0	Aucune relation logique

⚠ **Limite de la covariance** : elle dépend des unités de mesure. Comparer une covariance en FCFA avec une en km ne veut rien dire. C'est pour ça qu'on utilise la corrélation.

9.3 La corrélation de Pearson — intensité de la relation

Le **coefficient de corrélation de Pearson (r)** normalise la covariance. Il varie toujours entre **-1** et **+1**, quelle que soit l'unité.

```
r = +1 → Corrélation positive parfaite (droite montante)
r = 0 → Aucune corrélation linéaire
r = -1 → Corrélation négative parfaite (droite descendante)
```

Lecture pratique :

VALEUR DE R	INTERPRÉTATION
0.9 à 1.0	Très forte corrélation positive
0.7 à 0.9	Forte corrélation positive
0.4 à 0.7	Corrélation modérée
0.0 à 0.4	Corrélation faible ou nulle
Valeurs négatives	Même lecture, mais en sens inverse

⚠ **Le piège classique :** *"Corrélation n'est pas causalité."*

Exemple réel : dans certains pays, la consommation de chocolat est corrélée au nombre de Prix Nobel. Pourtant, manger du chocolat ne rend pas plus intelligent. Il peut y avoir une **variable cachée** (niveau de richesse du pays) qui explique les deux.

Un DA doit toujours se demander : *"Cette corrélation a-t-elle un sens logique ?"*

9.4 La corrélation de Spearman — quand Pearson ne suffit pas

Pearson mesure les **relations linéaires**. Mais parfois la relation est **monotone** (toujours dans le même sens) sans être une ligne droite parfaite.

La **corrélation de Spearman** travaille sur les **rangs** des valeurs plutôt que sur les valeurs elles-mêmes. Elle est plus robuste face aux outliers et aux distributions asymétriques.

SITUATION	UTILISER
Données normalement distribuées, relation linéaire	Pearson
Données avec outliers ou distribution asymétrique	Spearman
Variables ordinales (classements, notes)	Spearman

💡 *En pratique, un DA calcule souvent les deux et compare. Si les résultats sont proches, Pearson suffit.*

9.5 Le tableau de contingence — 2 variables catégorielles

Quand les 2 variables ne sont **pas numériques** (catégorielles), on ne peut pas calculer une corrélation. On utilise un **tableau de contingence** : il croise les deux variables et compte les occurrences.

Exemple : Région × Type de recharge acheté

	RECHARGE 500	RECHARGE 1000	FORFAIT INTERNET	TOTAL
Abidjan	1 240	890	2 100	4 230
Bouaké	980	430	560	1 970
San Pedro	620	210	180	1 010
Total	2 840	1 530	2 840	7 210

Ce qu'on peut lire directement :

- À Abidjan, le forfait internet est le produit le plus acheté → population plus connectée
- À Bouaké et San Pedro, la recharge 500 domine → comportement d'achat différent
- Cette différence régionale → 2 stratégies commerciales distinctes à envisager

💡 Le tableau de contingence est l'un des outils les plus utilisés en analyse business. Tu le retrouveras partout : Excel (TCD), SQL (GROUP BY sur 2 colonnes), Python (pivot_table).

15. Tableau récapitulatif — Notre dataset salaires

INDICATEUR	VALEUR	CE QUE ÇA DIT
Moyenne	817 k FCFA	Faussée par Jean-Marc — peu représentative
Médiane	410 k FCFA	La vraie "valeur centrale" — 5 personnes en dessous, 5 au-dessus
Mode	310 k FCFA	Salaire le plus fréquent dans l'équipe
Minimum	280 k FCFA	Salaire le plus bas
Maximum	4 500 k FCFA	Salaire le plus haut (Jean-Marc)
Étendue	4 220 k FCFA	Écart énorme — forte inégalité salariale
Distribution	Asymétrique à droite	Queue tirée par l'outlier Jean-Marc

Conclusion analytique :

"Les salaires de cette équipe sont fortement asymétriques, tirés vers le haut par un profil atypique. La médiane de 410 000 FCFA est bien plus représentative de la réalité vécue par les employés que la moyenne de 817 000 FCFA."

C'est exactement le type de phrase qu'un DA écrit dans un rapport.

16. Résumé du module

INDICATEUR	CE QU'IL MESURE	QUAND L'UTILISER
Type de variable	Nature de la donnée	Avant tout calcul — détermine les outils
Fréquence absolue	Nombre d'occurrences	Comptage brut
Fréquence relative	Proportion (%)	Reporting, communication business
Fréquence cumulée	Cumul des proportions	Pareto, seuils, top clients
Histogramme	Forme de la distribution	Première visualisation d'une variable continue
Moyenne	Centre des données	Données sans outliers, distribution symétrique
Médiane (Q2)	Valeur du milieu	Salaires, revenus, prix — résiste aux outliers
Mode	Valeur la plus fréquente	Données catégorielles, analyse de popularité
Étendue	Amplitude min → max	Première idée de la dispersion
Écart-type	Dispersion autour de la moyenne	Mesurer l'homogénéité d'un dataset
Q1 / Q3 / IQR	Dispersion des 50% centraux	Détecter les outliers, robuste aux extrêmes
Box plot	Résumé visuel Q1/Q2/Q3/outliers	Comparer des distributions
Distribution	Forme de la répartition	Choisir les bons indicateurs
Corrélation (Pearson/Spearman)	Relation entre 2 variables numériques	Analyser des liens entre indicateurs
Tableau de contingence	Relation entre 2 variables catégorielles	Croiser segments, régions, produits



Quiz — Vérifie ta compréhension

Réponds mentalement, puis clique sur "**Voir la réponse**" pour te corriger.

Q1. Sur 200 transactions, 50 concernent des recharges de 500 FCFA. Quelle est la fréquence relative ?

- a) 50
- b) 25%
- c) 150

 [Voir la réponse](#)

✓ **b) 25%** — Fréquence relative = $50 \div 200 = 0.25 = 25\%$. La fréquence absolue est 50, la fréquence relative est 25%. C'est ce dernier chiffre qu'on communique en reporting.

Q2. Un histogramme des salaires montre deux bosses distinctes — une autour de 300k et une autre autour de 900k FCFA. Qu'est-ce que ça suggère ?

- a) Les données sont normalement distribuées
- b) Il y a probablement deux groupes distincts dans les données
- c) La médiane est entre les deux bosses

 [Voir la réponse](#)

✓ **b) Deux groupes distincts** — Une distribution bimodale (deux bosses) signale souvent deux populations mélangées dans le même dataset. Probablement des profils junior et senior. Action recommandée : segmenter et analyser séparément.

Q3. Quelle est la différence principale entre un histogramme et un bar chart ?

- a) L'histogramme a des barres colorées, le bar chart non
- b) L'histogramme représente des variables continues avec des barres collées, le bar chart des catégories avec des barres séparées
- c) Il n'y a aucune différence

👉 Voir la réponse

✅ **b)** — L'histogramme représente la distribution d'une variable **quantitative continue** (barres collées). Le bar chart compare des **catégories distinctes** (barres séparées). Confondre les deux est une erreur classique de débutant.

Q4. Un DA reçoit une colonne "niveau de satisfaction" avec les valeurs : Faible / Moyen / Élevé / Très élevé. Quel type de variable est-ce ?

- a) Quantitative continue
- b) Qualitative nominale
- c) Qualitative ordinale

👉 Voir la réponse

✅ **c) Qualitative ordinale** — Il y a un ordre logique (Faible < Moyen < Élevé < Très élevé), mais on ne peut pas mesurer la distance entre les catégories. On peut calculer la médiane et le mode, mais pas la moyenne.

Q5. Un DA veut calculer la moyenne des codes postaux de ses clients. C'est :

- a) Correct — c'est une variable numérique
- b) Incorrect — les codes postaux sont une variable qualitative nominale
- c) Correct si on utilise la médiane

 [Voir la réponse](#)

✓ **b) Incorrect** — Même si les codes postaux sont des chiffres, ils représentent des catégories géographiques sans relation numérique. La moyenne de "00100" et "75008" ne représente rien de sensé. C'est une variable qualitative nominale.

Q6. Dans notre dataset salaires ($Q1=330$, $Q3=500$, $IQR=170$), un nouveau salarié arrive avec 820k FCFA/mois. Est-ce un outlier selon Tukey ?

- a) Non — 820 est proche de $Q3$
- b) Oui — 820 dépasse la borne supérieure de 755
- c) Impossible à dire

 [Voir la réponse](#)

✓ **b) Oui** — Borne supérieure = $Q3 + 1.5 \times IQR = 500 + 255 = 755$ k FCFA. Un salaire de 820k dépasse cette borne → outlier selon Tukey.

Q7. Un rapport indique que le temps de réponse d'une API est de 180ms au P95. Qu'est-ce que ça signifie ?

- a) 95% des requêtes prennent plus de 180ms
- b) La requête moyenne prend 180ms
- c) 95% des requêtes répondent en moins de 180ms

 [Voir la réponse](#)

✓ **c)** — Le P95 signifie que 95% des valeurs sont inférieures à ce seuil. Métrique standard en performance réseau et télécom.

Q8. Un DA analyse les prix de vente de 1 000 maisons. La plus chère vaut 50x la médiane. Quel indicateur utiliser ?

- a) La moyenne
- b) La médiane
- c) Le mode

👉 Voir la réponse

✅ **b) La médiane** — Avec un outlier aussi extrême, la moyenne sera complètement faussée. La médiane représente mieux le "prix typique".

Q9. Un opérateur télécom compare la qualité réseau de 200 antennes. Il veut savoir si la performance est homogène. Quel indicateur ?

- a) La moyenne
- b) Le mode
- c) L'écart-type

👉 Voir la réponse

✅ **c) L'écart-type** — Faible = antennes homogènes ✅ . Élevé = forte variabilité ⚠️ → action requise.

Q10. Dans 7 valeurs triées : **12 · 15 · 15 · 18 · 22 · 25 · 90** . Quelle est la médiane ?

- a) 22
- b) 28,1 (la moyenne)
- c) 18

👉 Voir la réponse

✅ **c) 18** — 7 valeurs (impair) → la médiane est la 4e : 12 · 15 · 15 · **18** · 22 · 25 · 90.

Q11. Un DA voit que **Moyenne > Médiane > Mode** . Quelle est la forme de la distribution ?

- a) Symétrique
- b) Asymétrique à gauche
- c) Asymétrique à droite

👉 Voir la réponse

✅ **c) Asymétrique à droite** — La moyenne est tirée vers la droite par des valeurs extrêmes élevées → Mode < Médiane < Moyenne.

Q12. Un DA obtient $r = 0.85$ entre antennes et abonnés. Qu'est-ce que ça signifie ?

- a) Les antennes causent directement l'augmentation des abonnés
- b) Forte corrélation positive — les deux variables évoluent ensemble
- c) La relation est faible

👉 Voir la réponse

✅ **b) Forte corrélation positive** — $r = 0.85$ indique une forte relation positive. Attention : ça ne prouve pas la causalité. Corrélation $\neq$ causalité.

Q13. Tu analyses la relation entre région (Abidjan, Bouaké, San Pedro) et type de forfait acheté. Quel outil ?

- a) Corrélation de Pearson
- b) Corrélation de Spearman
- c) Tableau de contingence

👉 Voir la réponse

✅ **c) Tableau de contingence** — Les deux variables sont catégorielles. Pas de corrélation possible — on croise et on compte.

Q14. Dataset de salaires avec outliers extrêmes. Tu mesures la corrélation ancienneté/salaire.

Tu utilises :

- a) Pearson
- b) Spearman
- c) Le mode

👉 Voir la réponse

✅ **b) Spearman** — Robuste face aux outliers car il travaille sur les rangs, pas les valeurs brutes.

- a) Correct — c'est une variable numérique - b) Incorrect — les codes postaux sont une variable qualitative nominale - c) Correct si on utilise la médiane

👉 Voir la réponse

✅ **b) Incorrect** — Même si les codes postaux sont des chiffres, ils représentent des catégories géographiques sans relation numérique. La moyenne de "00100" et "75008" ne représente rien de géographiquement sensé. C'est une variable qualitative nominale.

➡ Module suivant

Tu maîtrises maintenant les indicateurs de base pour **lire et décrire un dataset**.

On passe à la pratique : dans le **Module 03**, on ouvre Excel et on met les mains dans les données pour de vrai.

→ [Module 03 — Prise en main Excel / Google Sheets](#)