

Module 11 — Statistiques descriptives avec R & Python

Acte IV — R & Python pour l'analyse de données

Niveau : Débutant · Durée estimée : 3h00

Objectifs du module

À la fin de ce module, tu sauras :

- Charger un fichier CSV/Excel avec **pandas** (Python) et **base R**
- Calculer les indicateurs statistiques clés : moyenne, médiane, écart-type, quartiles
- Comprendre et interpréter chaque indicateur
- Détecter les **valeurs aberrantes** (outliers)
- Comparer des groupes avec **groupby** (Python) et **group_by** (R)
- Produire un **résumé statistique complet** d'un dataset

Mise en contexte — Bamba & Associés, Abidjan

Kouassi Ama a maintenant Python et R installés. M. Bamba lui confie le fichier RH des 35 employés :

"Ama, j'ai besoin d'un rapport statistique sur nos salaires. Qui gagne quoi ? Quelles sont les disparités entre départements ? Y a-t-il des salaires anormaux ?"

C'est exactement ce que les statistiques descriptives permettent de faire — rapidement, rigoureusement, et de façon reproductible.

1. Les indicateurs statistiques essentiels

1.1 Les indicateurs de tendance centrale

Ils répondent à la question : "Quelle est la valeur typique ?"

INDICATEUR	DÉFINITION	QUAND L'UTILISER
Moyenne	Somme / Nombre de valeurs	Distribution symétrique, sans outliers
Médiane	Valeur du milieu quand on trie	Distribution asymétrique, avec outliers
Mode	Valeur la plus fréquente	Variables catégorielles (ex : département)

Exemple concret — salaires Bamba & Associés :

Salaires (FCFA) : 300 000 · 350 000 · 380 000 · 420 000 · 1 800 000

Moyenne = $(300\,000 + 350\,000 + 380\,000 + 420\,000 + 1\,800\,000) / 5$
= $3\,250\,000 / 5 = 650\,000$ FCFA

Médiane = 380 000 FCFA (valeur du milieu après tri)

⚠ La moyenne (650 000) est **tirée vers le haut** par le salaire de 1 800 000.

La médiane (380 000) représente mieux la réalité de l'équipe.

Règle : quand moyenne $\neq$ médiane, il y a probablement des outliers.

1.2 Les indicateurs de dispersion

Ils répondent à : "Les valeurs sont-elles proches ou dispersées ?"

INDICATEUR	DÉFINITION	INTERPRÉTATION
Étendue	Max – Min	Plage totale des valeurs
Variance	Moyenne des écarts ² à la moyenne	Rarement utilisée directement
Écart-type	$\sqrt{\text{Variance}}$	Dispersion autour de la moyenne (même unité)
Quartiles Q1/Q3	25e et 75e percentile	Encadrement des 50% centraux
IQR	Q3 – Q1	Dispersion des 50% centraux (robuste aux outliers)

Exemple :

```

Équipe A – salaires : 400 000 · 410 000 · 420 000 · 430 000 · 440 000
Équipe B – salaires : 200 000 · 300 000 · 420 000 · 550 000 · 680 000

Moyenne A = Moyenne B = 420 000 FCFA ← identiques !
Écart-type A ≈ 15 811 FCFA ← équipe très homogène
Écart-type B ≈ 183 848 FCFA ← équipe très disparate

```

Même moyenne, mais des réalités très différentes. L'écart-type révèle ce que la moyenne cache.

1.3 Les quartiles et la boîte à moustaches

```

Données triées : 300k · 350k · 380k · 420k · 450k · 480k · 520k · 560k · 600k
· 650k · 1 800k

Q1 (25%) = 380 000 ← 25% des employés gagnent moins
Q2 (50%) = 480 000 ← médiane
Q3 (75%) = 560 000 ← 75% des employés gagnent moins
IQR      = Q3 - Q1 = 180 000

Seuil outlier bas  = Q1 - 1.5 × IQR = 380k - 270k = 110 000
Seuil outlier haut = Q3 + 1.5 × IQR = 560k + 270k = 830 000

→ 1 800 000 > 830 000 : c'est un outlier !

```

2. Le dataset — Fichier RH Bamba & Associés

On travaille sur un extrait du fichier RH (15 employés) :

NOM	DÉPARTEMENT	CONTRAT	SALAIRE (FCFA)	ANCIENNETÉ (ANS)
Kouassi Ama	RH	CDI	450 000	5
Kouamé Jean	Finance	CDI	620 000	8
Traoré Seydou	Commercial	CDI	380 000	3
Diabaté Fatou	RH	CDD	310 000	1
Bamba Koné	Direction	CDI	1 800 000	12
Ouédraogo Moussa	IT	CDI	580 000	6
Soro Aminata	Commercial	Stage	180 000	0
Koné Ibrahim	Finance	CDI	540 000	7
Yao Adjoua	IT	CDI	610 000	9
Diallo Mamadou	Commercial	CDD	340 000	2
Coulibaly Assata	RH	CDI	420 000	4
N'Guessan Éric	Finance	CDI	590 000	7
Touré Mariam	IT	Stage	200 000	0
Keita Souleymane	Commercial	CDI	360 000	3
Fofana Raïssa	Direction	CDI	950 000	10

Statistiques clés (vérifiées) :

INDICATEUR	VALEUR
Effectif	15
Masse salariale totale	8 330 000 FCFA
Salaire moyen	555 333 FCFA
Salaire médian	540 000 FCFA
Salaire minimum	180 000 FCFA
Salaire maximum	1 800 000 FCFA
Écart-type	393 215 FCFA
Q1 (25%)	360 000 FCFA
Q3 (75%)	610 000 FCFA

Ces chiffres sont les résultats attendus — tu peux vérifier tes calculs contre eux.

3. Statistiques descriptives en Python

3.1 Créer le DataFrame

PYTHON

```
import pandas as pd

data = {
    "nom": ["Kouassi Ama", "Kouamé Jean", "Traoré Seydou", "Diabaté Fatou",
           "Bamba Koné", "Ouédraogo Moussa", "Soro Aminata", "Koné Ibrahim",
           "Yao Adjoua", "Diallo Mamadou", "Coulibaly Assata", "N'Guessan
           Éric",
           "Touré Mariam", "Keita Souleymane", "Fofana Raïssa"],
    "departement": ["RH", "Finance", "Commercial", "RH", "Direction",
                    "IT", "Commercial", "Finance", "IT", "Commercial",
                    "RH", "Finance", "IT", "Commercial", "Direction"],
    "contrat": ["CDI", "CDI", "CDI", "CDD", "CDI", "CDI", "Stage", "CDI",
                "CDI", "CDD", "CDI", "CDI", "Stage", "CDI", "CDI"],
    "salaire": [450000, 620000, 380000, 310000, 1800000, 580000, 180000,
                540000, 610000, 340000, 420000, 590000, 200000, 360000,
                950000],
    "anciennete": [5, 8, 3, 1, 12, 6, 0, 7, 9, 2, 4, 7, 0, 3, 10]
}

df = pd.DataFrame(data)
print(df.shape)  # (15, 5) → 15 lignes, 5 colonnes
df.head()
```

3.2 Premier aperçu

PYTHON

```
# Infos générales
df.info()
# RangeIndex: 15 entries, 0 to 14
# Data columns (total 5 columns):
#  nom                15 non-null  object
#  departement        15 non-null  object
#  contrat             15 non-null  object
#  salaire             15 non-null  int64
#  anciennete          15 non-null  int64

# Résumé statistique automatique
df.describe()
```

	salaire	anciennete
# count	15.0	15.0
# mean	555333.3	5.1
# std	393215.0	3.6
# min	180000.0	0.0
# 25%	360000.0	2.5
# 50%	540000.0	5.0
# 75%	610000.0	8.0
# max	1800000.0	12.0

3.3 Calculs individuels

PYTHON

```
# Indicateurs de tendance centrale
print(f"Moyenne : {df['salaire'].mean():,.0f} FCFA")
# → Moyenne : 555,333 FCFA

print(f"Médiane : {df['salaire'].median():,.0f} FCFA")
# → Médiane : 540,000 FCFA

print(f"Mode : {df['departement'].mode()[0]}")
# → Mode : Commercial

# Indicateurs de dispersion
print(f"Écart-type : {df['salaire'].std():,.0f} FCFA")
# → Écart-type : 393,215 FCFA

print(f"Min : {df['salaire'].min():,.0f} FCFA")
print(f"Max : {df['salaire'].max():,.0f} FCFA")
# → Min : 180,000 FCFA
# → Max : 1,800,000 FCFA

# Quartiles
q1 = df['salaire'].quantile(0.25)
q3 = df['salaire'].quantile(0.75)
iqr = q3 - q1
print(f"Q1 : {q1:,.0f} FCFA")
print(f"Q3 : {q3:,.0f} FCFA")
print(f"IQR : {iqr:,.0f} FCFA")
# → Q1 : 360,000 FCFA
# → Q3 : 610,000 FCFA
# → IQR : 250,000 FCFA
```

3.4 Analyse par groupe (groupby)

PYTHON

```
# Salaire moyen par département
df.groupby('departement')['salaire'].mean().sort_values(ascending=False)

# departement
# Direction      1375000.0
# Finance         583333.3
# IT              463333.3
# RH              393333.3
# Commercial      315000.0

# Plusieurs indicateurs à la fois
df.groupby('departement')['salaire'].agg(['mean', 'median', 'min', 'max',
'count'])

#               mean    median    min    max    count
# departement
# Commercial      315000.0  360000.0  180000  380000      4
# Direction      1375000.0  1375000.0  950000  1800000      2
# Finance         583333.3  580000.0  540000  620000      3
# IT              463333.3  580000.0  200000  610000      3
# RH              393333.3  420000.0  310000  450000      3

# Répartition par type de contrat
df['contrat'].value_counts()

# CDI           10
# CDD            3
# Stage          2
```

3.5 Détecter les outliers

PYTHON

```
# Règle IQR : outlier si < Q1 - 1.5*IQR ou > Q3 + 1.5*IQR
seuil_bas = q1 - 1.5 * iqr
seuil_haut = q3 + 1.5 * iqr

print(f"Seuil bas : {seuil_bas:,.0f} FCFA")
print(f"Seuil haut : {seuil_haut:,.0f} FCFA")
# → Seuil bas : -15,000 FCFA (aucun outlier bas)
# → Seuil haut : 985,000 FCFA

outliers = df[df['salaire'] > seuil_haut]
print(outliers[['nom', 'departement', 'salaire']])
#          nom departement salaire
# 4  Bamba Koné   Direction 1800000
```

3b. Résumés rapides — les packages EDA

En pratique, les Data Analysts utilisent des packages qui génèrent un rapport complet **en une seule ligne de code**, sans avoir à calculer chaque indicateur à la main.

Les 3 packages incontournables

PACKAGE	RÉSULTAT	INSTALLATION
ydata-profiling	Rapport HTML interactif complet	<code>pip install ydata-profiling</code>
sweetviz	Rapport HTML visuel (comparaison possible)	<code>pip install sweetviz</code>
skimpy	Résumé console compact (style R's <code>skimr</code>)	<code>pip install skimpy</code>

ydata-profiling — Le plus complet

Génère un rapport HTML avec : statistiques, distributions, corrélations, valeurs manquantes, outliers.

PYTHON

```
pip install ydata-profiling
```

PYTHON

```
from ydata_profiling import ProfileReport

rapport = ProfileReport(df, title="RH Bamba & Associés")
rapport.to_file("rapport_rh.html")    # sauvegarde en HTML
# ou dans Jupyter :
rapport.to_notebook_iframe()          # affiche directement dans le notebook
```

Ce que le rapport contient automatiquement :

- Aperçu général (nb lignes, colonnes, valeurs manquantes, doublons)
- Pour chaque colonne numérique : moyenne, médiane, écart-type, min, max, Q1, Q3, histogramme
- Pour chaque colonne catégorielle : fréquences, valeurs uniques, graphique à barres
- Matrice de corrélations
- Détection des outliers et des valeurs extrêmes

sweetviz — Le plus visuel

PYTHON

```
pip install sweetviz
```

PYTHON

```
import sweetviz as sv

rapport = sv.analyze(df)
rapport.show_html("sweetviz_rh.html")
```

Avantage unique : comparer deux sous-datasets en un coup d'œil.

```
PYTHON
```

```
# Comparer CDI vs CDD
df_cdi = df[df['contrat'] == 'CDI']
df_cdd = df[df['contrat'] == 'CDD']

rapport = sv.compare(df_cdi, "CDI", [df_cdd, "CDD"])
rapport.show_html("comparaison_contrats.html")
```

skimpy — Le plus rapide (dans le terminal)

```
PYTHON
```

```
pip install skimpy
```

```
PYTHON
```

```
from skimpy import skim

skim(df)
```

Résultat dans la console (inspiré de `summary()` en R) :

```

skimpy summary

Data Summary
dataframe shape: (15, 5)
Missing values: 0

numeric

column | count | mean | std | min | median | Q1 |
-----|-----|-----|-----|-----|-----|-----|
salaire | 15 | 555 333 | 393 215 | 180 000 | 540 000 | 360 000 |
610 000 |
anciennete | 15 | 5.1 | 3.6 | 0 | 5 | 2.5 |
8

```

Quand utiliser quoi ?

SITUATION	PACKAGE RECOMMANDÉ
Première exploration d'un nouveau dataset	ydata-profiling
Présentation client / rapport à partager	sweetviz
Vérification rapide dans le terminal	skimpy
Contrôle précis indicateur par indicateur	pandas (<code>.describe()</code> , <code>.groupby()</code>)

💡 Workflow typique d'un DA :

1. `ydata-profiling` pour comprendre le dataset en 2 minutes
2. `pandas` pour les analyses ciblées et calculs spécifiques
3. Graphiques (M12) pour communiquer les résultats

4. Statistiques descriptives en R

4.1 Créer le data frame

```
R
df <- data.frame(
  nom = c("Kouassi Ama", "Kouamé Jean", "Traoré Seydou", "Diabaté Fatou",
    "Bamba Koné", "Ouédraogo Moussa", "Soro Aminata", "Koné Ibrahim",
    "Yao Adjoua", "Diallo Mamadou", "Coulibaly Assata", "N'Guessan
    Éric",
    "Touré Mariam", "Keita Souleymane", "Fofana Raïssa"),
  departement = c("RH", "Finance", "Commercial", "RH", "Direction",
    "IT", "Commercial", "Finance", "IT", "Commercial",
    "RH", "Finance", "IT", "Commercial", "Direction"),
  contrat = c("CDI", "CDI", "CDI", "CDD", "CDI", "CDI", "Stage", "CDI",
    "CDI", "CDD", "CDI", "CDI", "Stage", "CDI", "CDI"),
  salaire = c(450000, 620000, 380000, 310000, 1800000, 580000, 180000,
    540000, 610000, 340000, 420000, 590000, 200000, 360000,
    950000),
  anciennete = c(5, 8, 3, 1, 12, 6, 0, 7, 9, 2, 4, 7, 0, 3, 10)
)

dim(df)      # 15  5
head(df, 3)
```

4.2 Résumé automatique

```
R
summary(df)
#      salaire      anciennete
# Min.   : 180000   Min.     : 0.0
# 1st Qu.: 360000   1st Qu.: 2.5
# Median : 540000   Median    : 5.0
# Mean   : 555333   Mean      : 5.1
# 3rd Qu.: 610000   3rd Qu.: 8.0
# Max.   :1800000   Max.      :12.0
```

4.3 Calculs individuels

```
R
# Tendances centrale
mean(df$salaire)      # 555333.3
median(df$salaire)    # 540000

# Dispersion
sd(df$salaire)        # 393215.1 (écart-type)
var(df$salaire)       # 154618106667 (variance)
min(df$salaire)       # 180000
max(df$salaire)       # 1800000
range(df$salaire)     # 180000 1800000

# Quartiles
quantile(df$salaire)
#      0%      25%      50%      75%     100%
# 180000 360000 540000 610000 1800000

# IQR
IQR(df$salaire)       # 250000
```

4.4 Analyse par groupe

```
R
# Moyenne par département (base R)
tapply(df$salaire, df$departement, mean)
# Commercial    Direction    Finance          IT          RH
#      315000    1375000.0    583333.3    463333.3    393333.3

# Avec le package dplyr (plus lisible)
library(dplyr)

df %>%
  group_by(departement) %>%
  summarise(
    n          = n(),
    moyenne    = mean(salaire),
    mediane    = median(salaire),
    min        = min(salaire),
    max        = max(salaire)
  ) %>%
  arrange(desc(moyenne))

# # A tibble: 5 × 6
#   departement    n moyenne mediane    min    max
# 1 Direction      2 1375000 1375000 950000 1800000
# 2 Finance        3  583333  580000 540000  620000
# 3 IT             3  463333  580000 200000  610000
# 4 RH             3  393333  420000 310000  450000
# 5 Commercial     4  315000  360000 180000  380000

# Répartition par contrat
table(df$contrat)
# CDI    CDD Stage
# 10     3     2
```

4.5 Détecter les outliers

```
R
q1 <- quantile(df$salaire, 0.25) # 360000
q3 <- quantile(df$salaire, 0.75) # 610000
iqr <- IQR(df$salaire)          # 250000

seuil_haut <- q3 + 1.5 * iqr     # 985000
seuil_bas  <- q1 - 1.5 * iqr     # -15000

# Identifier les outliers
df[df$salaire > seuil_haut, c("nom", "departement", "salaire")]
#      nom departement salaire
# 5 Bamba Koné   Direction 1800000
```

5. Python vs R — Statistiques côte à côte

OPÉRATION	PYTHON (PANDAS)	R (BASE / DPLYR)
Charger CSV	<code>pd.read_csv("f.csv")</code>	<code>read.csv("f.csv")</code>
Dimensions	<code>df.shape</code>	<code>dim(df)</code>
Aperçu	<code>df.head()</code>	<code>head(df)</code>
Résumé complet	<code>df.describe()</code>	<code>summary(df)</code>
Moyenne	<code>df['col'].mean()</code>	<code>mean(df\$col)</code>
Médiane	<code>df['col'].median()</code>	<code>median(df\$col)</code>
Écart-type	<code>df['col'].std()</code>	<code>sd(df\$col)</code>
Quartiles	<code>df['col'].quantile([.25,.75])</code>	<code>quantile(df\$col)</code>
IQR	<code>q3 - q1</code>	<code>IQR(df\$col)</code>
Min / Max	<code>df['col'].min() / .max()</code>	<code>min(df\$col) / max(df\$col)</code>
Comptage catégories	<code>df['col'].value_counts()</code>	<code>table(df\$col)</code>
Grouper + agréger	<code>df.groupby('g')['v'].mean()</code>	<code>group_by(df,g) %>% summarise(m=mean(v))</code>
Filtrer outliers	<code>df[df['col'] > seuil]</code>	<code>df[df\$col > seuil,]</code>

Pont Excel → Python/R

Tout ce que tu faisais dans Excel a son équivalent direct :

FORMULE EXCEL	PYTHON	R
<code>=MOYENNE(B2:B16)</code>	<code>df['salaire'].mean()</code>	<code>mean(df\$salaire)</code>
<code>=MEDIANE(B2:B16)</code>	<code>df['salaire'].median()</code>	<code>median(df\$salaire)</code>
<code>=ECARTYPE(B2:B16)</code>	<code>df['salaire'].std()</code>	<code>sd(df\$salaire)</code>
<code>=MIN(B2:B16)</code>	<code>df['salaire'].min()</code>	<code>min(df\$salaire)</code>
<code>=MAX(B2:B16)</code>	<code>df['salaire'].max()</code>	<code>max(df\$salaire)</code>
<code>=QUARTILE(B2:B16;1)</code>	<code>df['salaire'].quantile(0.25)</code>	<code>quantile(df\$salaire, 0.25)</code>
<code>=NB.SI(C2:C16;"CDI")</code>	<code>(df['contrat']=='CDI').sum()</code>	<code>sum(df\$contrat == "CDI")</code>
TCD : moyenne par groupe	<code>df.groupby('dept') ['sal'].mean()</code>	<code>group_by(df,dept) %>% summarise(mean(sal))</code>

💡 **Avantage Python/R** : une seule ligne de code remplace un TCD entier — et elle se réexécute instantanément si les données changent.

Mini-exercices

Utilise le dataset RH Bamba & Associés (15 employés) défini en section 2.

Exercice 1 — Python : indicateurs d'ancienneté

Calcule les statistiques descriptives de la colonne `anciennete` :
moyenne, médiane, min, max, écart-type.

👉 Voir la réponse.....

PYTHON

```
print(f"Moyenne      : {df['anciennete'].mean():.1f} ans")
print(f"Médiane     : {df['anciennete'].median():.1f} ans")
print(f"Min         : {df['anciennete'].min()} ans")
print(f"Max         : {df['anciennete'].max()} ans")
print(f"Écart-type  : {df['anciennete'].std():.1f} ans")
```

```
# → Moyenne      : 5.1 ans
# → Médiane     : 5.0 ans
# → Min         : 0 ans
# → Max         : 12 ans
# → Écart-type  : 3.6 ans
```

Exercice 2 — R : salaire moyen par type de contrat

En R avec dplyr, calcule le salaire moyen et l'effectif pour chaque type de contrat (CDI, CDD, Stage).

👉 [Voir la réponse.....](#)

```
R
library(dplyr)

df %>%
  group_by(contrat) %>%
  summarise(
    effectif = n(),
    salaire_moyen = mean(salaire)
  ) %>%
  arrange(desc(salaire_moyen))

# # A tibble: 3 × 3
#   contrat  effectif  salaire_moyen
#   <fct>      <dbl>      <dbl>
# 1 CDI          10      646000
# 2 CDD           3      330000
# 3 Stage         2      190000
```

Exercice 3 — Python : identifier les employés sous le salaire médian

Filtre et affiche les employés dont le salaire est **strictement inférieur** à la médiane.
Affiche leur nom, département et salaire.

👉 Voir la réponse.....

PYTHON

```
mediane = df['salaire'].median()    # 540 000

sous_mediane = df[df['salaire'] < mediane][['nom', 'departement',
'salaire']]
print(sous_mediane.sort_values('salaire'))
```

```
#           nom departement  salaire
# 6      Soro Aminata  Commercial  180000
# 12     Touré Mariam           IT  200000
# 3     Diabaté Fatou           RH  310000
# 9     Diallo Mamadou  Commercial  340000
# 13    Keita Souleymane  Commercial  360000
# 2     Traoré Seydou  Commercial  380000
# 10   Coulibaly Assata           RH  420000
# 0      Kouassi Ama           RH  450000
```

Cheat Sheet — Statistiques descriptives

Indicateurs clés

INDICATEUR	PYTHON	R	EXCEL
Moyenne	<code>.mean()</code>	<code>mean()</code>	<code>=MOYENNE()</code>
Médiane	<code>.median()</code>	<code>median()</code>	<code>=MEDIANE()</code>
Écart-type	<code>.std()</code>	<code>sd()</code>	<code>=ECARTYPE()</code>
Variance	<code>.var()</code>	<code>var()</code>	<code>=VAR()</code>
Min	<code>.min()</code>	<code>min()</code>	<code>=MIN()</code>
Max	<code>.max()</code>	<code>max()</code>	<code>=MAX()</code>
Q1 (25%)	<code>.quantile(0.25)</code>	<code>quantile(x, 0.25)</code>	<code>=QUARTILE(x;1)</code>
Q3 (75%)	<code>.quantile(0.75)</code>	<code>quantile(x, 0.75)</code>	<code>=QUARTILE(x;3)</code>
IQR	<code>q3 - q1</code>	<code>IQR()</code>	<code>=QUARTILE(x;3)-QUARTILE(x;1)</code>
Résumé complet	<code>.describe()</code>	<code>summary()</code>	—

Quand utiliser quoi ?

SITUATION	INDICATEUR RECOMMANDÉ
Distribution symétrique (salaires similaires)	Moyenne + Écart-type
Distribution asymétrique (quelques très hauts salaires)	Médiane + IQR
Comparer des groupes	Moyenne ou médiane par groupe
Détecter des anomalies	Règle IQR ($Q3 + 1.5 \times IQR$)
Variable catégorielle (département, contrat)	Mode + <code>value_counts()</code> / <code>table()</code>



Quiz de validation

Question 1 — Les salaires de 5 employés sont : 300k, 350k, 380k, 420k, 1 800k FCFA.

Quel indicateur représente le mieux le salaire "typique" ?

- a) La moyenne (650 000 FCFA)
- b) La médiane (380 000 FCFA)
- c) L'écart-type
- d) Le maximum

👉 Voir la réponse.....

Réponse : b) La médiane (380 000 FCFA)

La moyenne est tirée vers le haut par le salaire exceptionnel de 1 800 000. La médiane — valeur du milieu après tri — est plus représentative de ce que gagne un employé "typique" dans cette équipe. Règle : quand il y a des outliers, préférer la médiane.

Question 2 — En Python, quelle ligne donne le salaire moyen par département ?

- a) `df['salaire'].mean('departement')`
- b) `df.groupby('departement')['salaire'].mean()`
- c) `df.mean(by='departement')`
- d) `df['departement'].mean('salaire')`

👉 Voir la réponse.....

Réponse : b) `df.groupby('departement')['salaire'].mean()`

La méthode `groupby()` regroupe les lignes selon une colonne, puis on applique `.mean()` (ou n'importe quelle agrégation) sur la colonne numérique souhaitée.

Question 3 — Un employé gagne 1 800 000 FCFA. Q1 = 360 000, Q3 = 610 000, IQR = 250 000.

Est-ce un outlier selon la règle IQR ?

- a) Non, car c'est un Directeur
- b) Non, le seuil haut est 2 000 000
- c) Oui, le seuil haut est 985 000 et 1 800 000 > 985 000
- d) On ne peut pas savoir sans le graphique

👉 Voir la réponse.....

Réponse : c)

Seuil haut = $Q3 + 1.5 \times IQR = 610\,000 + 1.5 \times 250\,000 = 610\,000 + 375\,000 = 985\,000$ FCFA.
1 800 000 > 985 000 → c'est bien un **outlier statistique**. Ça ne veut pas dire que le salaire est illégitime (c'est le Directeur), mais il sort de la distribution normale et doit être noté dans l'analyse.

✅ Résumé du module

CE QUE TU AS APPRIS	DÉTAIL
Tendance centrale	Moyenne, médiane, mode — quand utiliser quoi
Dispersion	Écart-type, IQR, quartiles
Résumé automatique	<code>df.describe()</code> (Python) · <code>summary(df)</code> (R)
Grouper + agréger	<code>groupby()</code> (Python) · <code>group_by() %>% summarise()</code> (R)
Détecter les outliers	Règle IQR : $Q3 + 1.5 \times IQR$
Pont Excel → Python/R	MOYENNE, MEDIANE, ECARTYPE traduits

🚀 Dans le module suivant

Module 12 — Visualisation avec R & Python

On transforme ces chiffres en graphiques : histogrammes, boîtes à moustaches, barres, nuages

de points — avec **matplotlib/seaborn** (Python) et **ggplot2** (R).

Bootcamp Data Analyst — From Zero to Hero / Niveau Débutant · Acte IV